

# 基于机器学习的动态因子轮动策略研究

以上证 50 成分股为例：从 Regime 识别到 LSTM 动态配置

周屹玺，李红瑶，王跃众

上海科技大学

20251219

# 汇报目录

- ① 研究动机与因子轮动的理论背景
- ② 轮动基础：数据与市场状态实证
- ③ 因子轮动策略框架与权重生成机制
- ④ 模型训练数据集的构建与样本划分
- ⑤ 构建因子轮动预测模型
- ⑥ 动态因子策略回测结果
- ⑦ 结论与研究展望

# 研究动机：因子配置是否应当保持不变？

- 传统多因子投资框架通常假设：
  - 各类风格因子在长期内能够持续提供稳定的风险溢价；
  - 因而在实务中多采用静态或准静态的因子权重配置方式。
- 然而，近年来的理论与实证研究表明：
  - 因子收益并非时间不变；
  - 其表现呈现出明显的阶段性、周期性与结构性变化。

# 因子收益非平稳性的经济直觉

- 不同因子对应不同的风险补偿机制，其有效性依赖于市场环境：
  - 动量因子依赖趋势延续，在方向性明确的市场中更为有效；
  - 价值因子反映均值回归，在风险溢价上升或情绪悲观阶段具备防御属性；
  - 质量因子强调盈利能力与稳健性，在震荡或不确定性较高的环境中表现相对占优；
  - 低波动与规模因子往往与风险偏好与资金结构变化密切相关。
- 因此，单一或静态的因子配置方式：
  - 可能在特定阶段表现良好；
  - 却在其他阶段出现系统性失效。

# 因子轮动的核心思想

- 因子轮动理论的基本观点：
  - 因子溢价具有显著的时间变化特征；
  - 因子表现与市场所处的宏观与风险状态密切相关。
- 若能够在一定程度上刻画当前市场环境，并预测下一阶段不同因子的相对强弱：
  - 则有可能通过动态调整因子权重；
  - 在风险可控的前提下提升组合的风险调整后收益。

# 因子轮动在实践中的关键挑战

- 因子轮动策略在实际应用中面临两项核心困难：
- 挑战一：市场状态不可直接观测
  - 市场环境的划分往往具有较强主观性；
  - 缺乏客观、可重复的数据驱动识别方法。
- 挑战二：因子收益的动态演化复杂
  - 因子收益具有显著的时序相关性与噪声特征；
  - 简单规则或静态判断难以刻画其变化过程。

## 研究思路：从因子轮动到数据驱动建模

- 本研究将因子轮动问题拆解为两个相互关联的子问题：
- 第一步：市场状态识别
  - 基于指数层面的市场特征，识别不同市场状态；
  - 从实证角度检验因子收益的状态依赖性是否存在。
- 第二步：因子收益预测与配置
  - 利用机器学习模型刻画因子收益的时间序列结构；
  - 预测下一期各因子的相对表现，并生成动态因子权重。

# 研究对象与研究目标

- 研究对象选择：
  - 以上证 50 指数成分股作为股票池；
  - 兼顾样本稳定性与市场代表性。
- 研究目标：
  - 重点关注动态因子配置在样本外阶段的表现；
  - 检验其是否能够相较于静态多因子策略，
  - 实现更优的风险调整后收益。
- 最终目标：
  - 构建一套可复现、可扩展的数据驱动因子轮动研究范式。



# 研究对象与数据结构：两类数据、统一月度对齐

- 股票池：上证 50 指数成分股（大市值、流动性强、噪声与交易约束相对更小）。
- 时间频率：月度（用于状态识别、因子收益序列建模与调仓回测）。
- 两类核心数据（按月严格对齐）：
  - ① 因子层面：因子多空收益时间序列（刻画因子溢价随时间变化）。
  - ② 指数层面：市场特征（用于识别市场状态 Regime）。
- 关键一致性处理：所有日期统一映射为对应月份的第一天作为时间索引，确保调仓点信息不穿越。

# 数据示例：原始因子与指数数据片段

- 选取部分原始数据片段展示本研究所用数据的基本结构：
  - 个股与因子层面的原始输入；
  - 回测过程中使用的关键字段与格式。

month	MOM20	MOM120	RSI	PB
2015-01-01	0.0	0.0	0.0	0.0
2015-02-01	-4.220000000000001	-4.220000000000001	-7.76	-4.6499999999999995
2015-03-01	1.84	1.84	3.4399999999999995	-2.6799999999999997
2015-04-01	-7.83	-7.83	-3.8599999999999999	2.960000000000001
2015-05-01	-9.61	-9.61	-2.2	-10.82
2015-06-01	-10.200000000000005	-10.200000000000005	-6.94	23.979999999999997
2015-07-01	-3.34	-3.34	-1.1000000000000014	6.51
2015-08-01	11.62	11.62	4.020000000000001	4.36
2015-09-01	-3.66	-3.66	-2.8400000000000003	7.1099999999999999
2015-10-01	-2.5700000000000003	-2.5700000000000003	-3.810000000000001	-7.700000000000001
2015-11-01	4.93	4.93	7.34	3.88
2015-12-01	5.24	5.24	4.41	-0.1600000000000001
2016-01-01	1.3300000000000018	1.3300000000000018	4.530000000000001	8.340000000000002
2016-02-01	5.36	5.36	3.7299999999999999	1.0
2016-03-01	-7.990000000000002	-7.990000000000002	-6.910000000000002	-6.93
2016-04-01	-6.08	-6.08	-0.77	4.64

# 风格因子选择：经典且可解释

- 研究目标是验证“轮动机制”而非穷举因子，因此选择经典且经济含义清晰的风格因子：
  - 动量 (Momentum): MOM20, MOM120, RSI<sup>1</sup>
  - 价值 (Value):  $PB^{-1}$ ,  $PE^{-1}$ ,  $DIV^2$
  - 质量 (Quality): ROE, PROFIT\_GR<sup>3</sup>
  - 风险相关 (Risk-related): VOL, BETA<sup>4</sup>
- 这样做的好处：
  - 降低高维因子带来的过拟合风险；
  - 保留清晰的经济直觉，便于解释“为什么轮动”。

<sup>1</sup> Jegadeesh, N. and Titman, S. (1993), "Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency," *Journal of Finance*; Moskowitz, T.J., Ooi, Y.H. and Pedersen, L.H. (2012), "Time Series Momentum," *Journal of Financial Economics*; Lo, A.W., Mamaysky, H. and Wang, J. (2000), "Foundations of Technical Analysis: Computational Algorithms, Statistical Inference, and Empirical Implementation," *Journal of Finance*.

<sup>2</sup> Fama, E.F. and French, K.R. (1992), "The Cross-Section of Expected Stock Returns," *Journal of Finance*; Lakonishok, J., Shleifer, A. and Vishny, R.W. (1994), "Contrarian Investment, Extrapolation, and Risk," *Journal of Finance*.

<sup>3</sup> Novy-Marx, R. (2013), "The Other Side of Value: The Gross Profitability Premium," *Journal of Financial Economics*; Fama, E.F. and French, K.R. (2015), "A Five-Factor Asset Pricing Model," *Journal of Financial Economics*.

<sup>4</sup> Frazzini, A. and Pedersen, L.H. (2014), "Betting Against Beta," *Journal of Financial Economics*; Ang, A., Hodrick, R.J., Xing, Y. and Zhang, X. (2006), "The Cross-Section of Volatility and Expected Returns," *Journal of Finance*.

# 从横截面信号到时间序列：因子多空收益（Long-Short）

- 目的：把“因子暴露”转换为可建模的因子收益序列。
- 月度调仓日：对成分股按某因子值排序，构造五分位组合（G1-G5）。
- 定义因子多空收益：

$$r_{t,f}^{LS} = r_{t,f}^{G5} - r_{t,f}^{G1}$$

- 解释：通过多空构造在较大程度上剥离市场整体方向，更直接度量因子溢价的时间变化。

# 市场状态信息：用指数层面特征刻画“环境”

- Regime 识别不使用个股微观信息，而使用上证 50 指数特征，刻画整体环境：
  - 月度指数收益率（ret\_month）
  - 20 日（及扩展：60 日）年化波动率（vol\_20\_annual\_month\_end 等）
  - 月度成交量总和（vol\_month\_sum）及成交量变化率（可选扩展）
- 三个维度对应直觉：
  - 收益：方向与趋势
  - 波动：风险强度/不确定性
  - 成交：交易活跃度/情绪与资金参与
- 工程处理：所有特征进入模型前标准化，避免量纲影响聚类。

# 市场状态识别所用数据示例

- 本图展示用于 Regime 聚类的上证 50 指数层面特征数据片段：
  - 包括月度收益率、波动率与成交量等列；
  - 为后续 KMeans 聚类提供输入基础。

month	close_month_end	ret_month	vol_month_sum	vol_month_chg
2015-01-31	2405.38	-0.06824916620506127	240759567500	-0.372973880611544
2015-02-28	2474.59	0.02877300052382581	113685256600	-0.5278058613392383
2015-03-31	2754.66	0.11317834469548482	257993309000	1.2693647066984761
2015-04-30	3250.49	0.17999680541337226	368238254400	0.4273170720098016
2015-05-31	3111.33	-0.042812006805127756	259537919800	-0.29519022888350954
2015-06-30	2870.03	-0.07755525771936755	348849950200	0.34411938906200645
2015-07-31	2461.24	-0.14243405121200836	420513910900	0.2054291842636473
2015-08-31	2210.45	-0.10189579236482427	186680679100	-0.5560653898453469
2015-09-30	2146.12	-0.029102671401750713	117200273900	-0.37218851749934523
2015-10-31	2312.97	0.07774495368385725	82863638300	-0.2929740217953535
2015-11-30	2336.29	0.010082275170019583	131944299600	0.5923063759559783
2015-12-31	2420.8	0.03617273540527943	102200640800	-0.2254258720548773
2016-01-31	1973.01	-0.1849760409781891	70174227400	-0.3133680292932175
2016-02-29	1944.61	-0.014394250409273224	45748214900	-0.34807668577196194
2016-03-31	2156.54	0.10898329227968584	94512585400	1.0659294708349374
2016-04-30	2135.51	0.00751731040070447	53183303600	0.44787005831771365

# Regime 划分方法：KMeans 无监督聚类 + 轮廓系数选 K

- 选择无监督聚类而非“人为划分牛熊”：
  - 状态边界不预设，确保可重复与客观；
  - 用数据自行决定哪些月份在特征空间中更相似。
- 算法：KMeans 对月度特征向量聚类，输出每月状态标签  $z_t \in \{0, 1, 2\}$ 。
- 聚类数  $K$  的选择：比较不同  $K$  下的 **Silhouette Score**，
  - 在类内相似性与类间差异性之间权衡；
  - 兼顾稳定性与经济解释性，最终取  $K = 3$ 。

## 16 / 59



---

## 本节结论：为何可以进入“预测 → 动态权重”主线？

- 结论 1：市场状态可由指数特征客观识别，且三类状态在收益/风险/成交维度具有稳定区分。
- 结论 2：因子收益存在显著状态依赖性，不同风格因子在不同 Regime 下强弱系统性变化。
- 因此：
  - 静态因子权重难以跨环境保持最优；
  - 将问题转化为可学习任务：用历史因子收益（及 Regime 辅助信息）预测下一期因子相对表现，
  - 再据此生成可执行的动态因子权重。

# 核心问题：预测因子收益之后，如何形成可执行策略？

- 前两部分已表明：
  - 因子收益具有显著的时间变化与状态依赖性；
  - 因子轮动在经济直觉与实证层面均具有合理性。
- 进一步的问题是：
  - 若能够预测下一期各因子的相对表现，
  - 如何将预测结果转化为连续、可控、可回测的因子配置权重？
- 本研究关注的是因子层面的配置问题，
  - 而非个股择时或择股问题。

# 因子轮动策略的整体流程

- ① 基于历史数据，对下一期各因子多空收益进行预测；
  - ② 将预测得到的因子收益向量映射为因子配置权重；
  - ③ 在因子层面构建组合，并映射到股票组合进行回测。
- 该流程的核心在于：
    - 因子权重随时间连续变化；
    - 不依赖人工规则或离散切换。

## 预测目标的定义：预测“因子相对强弱”，而非绝对收益

- 本研究中，模型的预测对象为：
  - 下一期十个因子的多空收益向量
- 关注重点并非预测值本身是否精确，
  - 而是因子之间的相对排序与强弱结构。
- 因此：
  - 即使存在一定预测误差，
  - 只要相对排序具有信息含量，
  - 就有可能改善因子配置效果。

## 最终建模数据集：统一的时间序列输入

- 在完成因子多空收益与市场状态（Regime）标签合并后，
- 构建用于机器学习建模的最终数据集：
  - `final_factor_longshort.csv`
  - 月度频率，是后续模型训练、验证与预测的唯一中心数据源
- 数据集中每一行对应一个月份，包含：
  - 十个风格因子的多空收益（G5–G1）
  - 当期市场状态 Regime 标签

## 数据来源与时间范围

- 最终数据集由以下两类数据按月严格对齐后构建：
- 因子多空收益数据（factor\_longshort.csv）
  - 基于上证 50 成分股
  - 月末横截面排序、五分位分组
  - 计算高分组减低分组（G5—G1）得到因子收益
- 市场状态数据（cluster\_info）
  - 基于指数特征的 KMeans 聚类结果
  - 为每个月分配唯一 Regime 标签
- 合并后时间范围：
  - **2015-01-01 至 2024-12-01**
  - 连续、无缺失的月度观测

# 监督学习样本的构造：滑动窗口设定

- 为构造适用于时间序列模型的监督学习样本，
- 采用长度为 **12** 个月的滑动窗口（rolling window）。
- 在任意预测时点  $t$ ：
  - 输入  $X_t$ ：  $t - 12$  至  $t - 1$  的历史信息
  - 输出  $y_t$ ： 第  $t$  个月的因子多空收益
- 该设定确保模型在任意时点的预测，
  - 仅基于当时可获得的历史数据，
  - 符合真实投资场景下的信息约束。



# 模型输入特征的组成

- 模型输入特征由两部分在时间维度上拼接而成：
- 因子收益特征
  - 十个因子的历史多空收益序列
  - 刻画因子溢价自身的时间依赖结构
- 市场状态特征
  - Regime 标签经 one-hot 编码后引入
  - 显式刻画不同市场环境下的因子表现差异
- 该联合输入结构使模型能够同时利用：
  - 因子内部动态信息
  - 以及外部环境信息

# 样本划分原则：严格的时间顺序切分

- 金融时间序列建模中，随机划分样本会导致严重的数据泄漏风险；
- 本研究采用严格按时间顺序的前推切分。
- 全部监督学习样本按比例划分为：
  - 训练集（70%）：用于模型参数学习
  - 验证集（20%）：用于结构选择与训练过程监控
  - 测试集（10%）：仅用于样本外预测与回测评估

## 测试集时间区间与样本外评估

- 测试集对应样本期末的时间区间：
  - **2024-02-01 至 2024-12-01**
- 在该区间内：
  - 模型参数已完全由训练集与验证集确定；
  - 测试集数据不参与任何形式的训练或调参；
  - 仅用于生成因子收益预测与后续动态权重回测。
- 因此，该区间构成本文结论的核心样本外检验窗口。

# 数据穿越与前视偏差的控制说明

- 本研究在数据构建与模型训练过程中不存在数据穿越或前视偏差：
- 特征层面
  - 因子收益与 Regime 标签均基于当期及之前信息计算；
  - 不使用任何未来数据。
- 样本划分层面
  - 训练、验证、测试集严格按时间顺序切分；
  - 测试集不参与模型训练与参数选择。

# 预测—配置—回测的时间一致性

- 在测试集的每一个月份  $t$  :
  - 模型仅使用  $t - 1$  及之前 12 个月的信息进行预测；
  - 基于预测的因子收益生成当期因子权重；
  - 再用于  $t$  期的策略配置与回测。
- 整个流程严格遵循：
  - 先预测、再配置、后实现收益的时间顺序；
- 因此，最终结果具有真实投资场景下的可解释性与可信用度。

## 建模目标：预测下一期因子相对表现

- 在完成数据集构建与样本划分后，进入机器学习建模阶段。
- 本研究的预测目标并非：
  - 个股收益，或市场方向；
- 而是：
  - 下一期十个风格因子的多空收益向量。
- 该设定的核心关注点在于：
  - 因子之间的相对强弱结构，
  - 而非单一因子收益预测的绝对精度。

---

# 模型选择：LSTM 时间序列预测框架

- 因子收益序列具有以下特征：
  - 显著的时间依赖性；
  - 非平稳性与阶段性变化；
  - 对近期历史信息更为敏感。
- 因此选择 LSTM (Long Short-Term Memory) 模型：
  - 显式建模时间序列依赖结构；
  - 在有限样本下相对稳健；
  - 能够自然接收多维时序输入。



# 模型输入输出的张量结构

- 输入样本  $X_t$ :
  - 过去 12 个月的历史序列;
  - 每个时间步包含:
    - 10 个因子多空收益;
    - 市场 Regime 的 one-hot 编码特征。

- 张量维度表示为:

$$X \in \mathbb{R}^{(\text{样本数}, 12, \text{特征数})}$$

- 输出  $y_t$ :
  - 第  $t$  个月的十维因子多空收益向量;
  - 属于典型的多输出回归问题。

# LSTM 网络结构概览

- 网络采用 Keras Sequential 框架构建，结构如下：
- **LSTM 层 (64 units)**
  - 输入形状：(12, 特征数)
  - 将历史序列压缩为一个时序表示向量
- **Dropout (0.2)**
  - 用于降低过拟合风险
- **Dense 层 (32 units, ReLU)**
  - 提升非线性表达能力
- **输出层 (10 units, Linear)**
  - 同时输出十个因子的预测收益

# 损失函数、优化器与训练策略

- 损失函数：
  - 均方误差 (MSE)，适用于连续型回归问题
- 优化器：
  - Adam (学习率 0.001)，在噪声梯度环境下较为稳健
- 训练策略：
  - 训练轮数：80 epochs
  - 批大小：16
  - 同步监控验证集损失以评估泛化能力

# 样本外预测与时间索引对齐

- 模型训练完成后，在测试集上执行预测：
  - 输入  $X_{\text{test}}$
  - 输出因子收益预测矩阵  $y_{\text{pred}}$
- 由于采用 12 个月滑动窗口：
  - 预测结果需进行严格的时间索引对齐；
  - 确保每一行预测对应真实的预测月份。
- 最终导出：
  - `factor_prediction.csv`
  - 结构为：month + 各因子预测列 (`_pred`)

## 本节小结：模型在整体框架中的角色

- 本节构建了一个：
  - 基于历史因子收益与市场状态信息的
  - 多任务时间序列预测模型。
- 模型输出并不直接用于交易，
  - 而是作为后续因子权重生成（softmax 映射）的输入。
- 下一部分将基于预测结果：
  - 构建动态因子权重，
  - 并通过回测系统性评估因子轮动策略的有效性。

## 回测设定与统一口径

- 回测目标：检验“预测因子收益  $\rightarrow$  softmax 映射  $\rightarrow$  动态因子权重”是否能在风险可控前提下带来实质性的收益--风险改进。
- 统一口径：
  - 测试区间（样本外）：2024-02-01 – 2024-12-01
  - 基准：上证 50 指数
  - 调仓频率：月度
  - 组合口径：高因子组合

# 特征标准化与归一化示例

- 在进入回测前，对多维特征进行标准化/归一化处理：

	month	MOM20_w	MOM120_w	RSI_w	PB_w	PE_w	DIV_w	ROE_w	PROFIT_GR_w
1	2024-02-01	0.00	0.00	0.00	0.00	0.00	0.00	0.04	0.96
2	2024-03-01	0.21	0.12	0.15	0.00	0.00	0.00	0.14	0.37
3	2024-04-01	0.01	0.01	0.08	0.00	0.02	0.04	0.67	0.15
4	2024-05-01	0.01	0.01	0.03	0.01	0.03	0.03	0.47	0.37
5	2024-06-01	0.00	0.00	0.00	0.00	0.00	0.00	0.19	0.81
6	2024-07-01	0.00	0.00	0.00	0.00	0.00	0.00	0.38	0.62
7	2024-08-01	0.00	0.00	0.00	0.00	0.00	0.00	0.43	0.56
8	2024-09-01	0.00	0.00	0.00	0.00	0.00	0.00	0.17	0.83
9	2024-10-01	0.00	0.00	0.00	0.03	0.01	0.02	0.61	0.18
10	2024-11-01	0.00	0.00	0.00	0.01	0.00	0.00	0.11	0.49
11	2024-12-01	0.00	0.00	0.00	0.00	0.00	0.00	0.26	0.59
12									

## 回测示意：策略净值与关键字段

- 展示回测结果中的典型记录格式与净值/收益率曲线示意：

```

// =====
// 5) 完整回测函数
// =====
Function Run_Dynamic_Weights_Backtest();
Begin
    obj := CreateObject('MultiFactorDynamic');

    obj.FBegT    := 20240201T;
    obj.FEndT    := 20241201T;
    obj.FCycle   := cy_month();
    obj.FIndexId := 'SH000016';

    // 因子库：比例先 0，运行时由 GetFactors 写入动态权重
    obj.FFactorArr := array(
        ('因子名称', 'MOM20',      '因子公式', 'StockZf2(20)',
        ('因子名称', 'MOM120',     '因子公式', 'StockZf2(120)',
        ('因子名称', 'RSI',         '因子公式', 'RSI_f(14, 0)',

        ('因子名称', 'PNA',         '因子公式', '1/StockPNA_VI(EndT)',
        ('因子名称', 'PE_TTM',      '因子公式', '1/StockPE_VI(EndT)',
        ('因子名称', 'DIV',         '因子公式', 'StockDividendYieldRatio(EndT)',

        ('因子名称', 'ROE_TTM',     '因子公式', 'Last12MData(RDate, 9900100)',
        ('因子名称', 'Profit_Growth', '因子公式', 'Last12MData(RDate, 9900602)',
        ('因子名称', 'STD_60',      '因子公式', 'StockRisk("SH000016", IncYear(EndT,
        ('因子名称', 'BETA',        '因子公式', 'StockBeta("SH000016", IncMonth(EndT, -

    );

    obj.W := GetDynamicWeightsWithoutRegimeV1();
  
```



## 对照策略定义（四策略）

- 等权多因子 (Equal-weight): 10 个因子固定等权 (各 10%), 不使用 Regime/预测。
- 规则配置 (Rule-based): 规则驱动的静态配置 (不依赖机器学习预测)。
- 动态权重 (有 Regime): 使用预测 + Regime 特征, softmax 生成当期权重, 月度更新。
- 动态权重 (无 Regime): 仅使用预测 (不含 Regime 特征), softmax 生成当期权重, 月度更新。

# 策略核心指标总览

策略	CAGR	Vol	Sharpe	Sortino	Calmar	MaxDD	DD(月)	WinRate
等权配置	21.24%	20.56%	1.0294	4.6733	5.4106	-3.93%	3	0.50
规则配置	23.13%	32.75%	0.7754	2.3725	1.6603	-13.93%	6	0.50
动态权重 (有状态)	36.71%	29.77%	1.1856	3.4556	3.8853	-9.45%	3	0.60
动态权重 (无状态)	<b>40.09%</b>	26.87%	<b>1.3806</b>	<b>6.3496</b>	<b>13.1028</b>	<b>-3.06%</b>	<b>2</b>	<b>0.70</b>


- 动态权重（无状态）在 CAGR、Sharpe、Calmar 与最大回撤控制上同时占优。

# 累计收益：期末值对比

策略	期末累计收益	基准期末累计收益
等权配置	17.42%	10.03%
动态权重 (有状态)	29.77%	10.03%
动态权重 (无状态)	32.46%	10.03%
规则配置	18.93%	10.03%

# 累计收益曲线

- 建议插入：四策略与基准的累计收益率曲线图。




## 相对基准表现 (CAPM / IR)

策略	年化超额收益	Tracking Error	IR	CAPM Alpha(年化)
等权配置	0.0909	0.0733	1.0552	0.0910
动态权重 (有状态)	0.2455	0.1743	1.2547	0.2014
动态权重 (无状态)	<b>0.2794</b>	0.1600	<b>1.4792</b>	<b>0.2363</b>
规则配置	0.1098	0.2154	0.5554	0.0986

- 动态权重（无状态）在年化超额收益与信息比率（单位跟踪误差效率）上同时领先。


# 信息比率对比

- 四策略 Information Ratio 柱状图。




# 回撤曲线对比

- 四策略（第 5 组）回撤曲线图，用于展示尾部风险差异与修复速度。



## Sharpe 对比

- 四策略 Sharpe Ratio 柱状图, 与上页 IR 柱状图构成“风险调整后收益 + 相对基准”双证据)。





## 换手率与单位换手收益（交易成本代理）

策略	平均换手率 (%)	平均月度收益 (%)	单位换手收益
等权配置	51.1111	1.7640	0.0345
动态权重 (有状态)	<b>24.4444</b>	2.9410	<b>0.1203</b>
动态权重 (无状态)	42.2222	<b>3.0910</b>	0.0732
规则配置	32.2222	2.1160	0.0657

- 含 Regime 版本在更低换手下单位效率更高；无 Regime 版本收益更高但换手相对更大。

# 因子层面诊断：多空收益（Top-Bottom）与 IC

策略	多空 CAGR	多空 Vol	多空 Sharpe	多空 MaxDD	多空 WinRate
等权配置	0.0074	0.0964	0.1195	-0.0445	0.40
动态权重 (有状态)	-0.2450	0.1678	-1.5749	-0.2403	0.30
动态权重 (无状态)	-0.2655	0.2161	-1.3010	-0.2506	0.50
规则配置	-0.0715	0.2393	-0.1966	-0.2295	0.40

策略	IC Mean	IC Std	IC_IR (年化)
等权配置	-0.0300	0.1416	-0.7339
动态权重 (有状态)	-0.0878	0.1892	-1.6072
动态权重 (无状态)	-0.0833	0.2575	-1.1209
规则配置	0.0167	0.2819	0.2048

## 因子区分度检验 (T-Stat / P-Value)

策略	T_Stat	P_Value
等权配置	0.11	54.18
动态权重 (有状态)	-1.45	9.29
动态权重 (无状态)	-1.19	13.38
规则配置	-0.18	43.13

- 该组“因子层面”统计并未显示传统意义上的显著增强；
- 动态权重的优势更可能来自组合层面权重调整对收益路径/风险暴露的工程性改良。

# 回测结论

- 动态权重策略整体优于静态策略：CAGR 与 Sharpe/IR 同时提升。
- 最优策略为动态权重（无状态）：
  - CAGR 40.09%，Sharpe 1.3806，IR 1.4792，MaxDD -3.06%。
- Regime 的边际贡献在本样本外区间内有限或不稳定：
  - 含 Regime 版本 CAGR 36.71%，Sharpe 1.1856，IR 1.2547，且回撤更深。

## 研究问题回顾

- 本研究围绕一个核心问题展开：
  - 在中国股票市场中，
  - 因子收益具有显著时间变化特征的背景下，
  - 是否可以通过数据驱动的方法，
  - 构建有效的因子轮动策略？
- 为回答该问题，本文构建了一套完整流程：
  - 因子构建与多空收益提取；
  - 市场状态（Regime）的无监督识别；
  - 基于时间序列的因子收益预测；
  - 动态因子权重映射与样本外回测评估。

## 核心结论一：动态因子权重在组合层面显著有效

- 样本外回测结果表明：
  - 基于因子收益预测并通过 softmax 映射得到的动态因子权重，
  - 在收益水平与风险调整后表现上，
  - 均显著优于等权配置与规则型静态策略。
- 更重要的是：
  - 收益提升并非以放大波动或回撤为代价；
  - 在 Sharpe、IR、Calmar 等多维指标下均表现更优。

## 核心结论二：优势来自权重机制，而非因子显著性增强

- 在因子层面统计检验中：
  - 多空组合收益整体偏弱；
  - IC 均值与显著性检验未显示明显改善。
- 这表明：
  - 动态因子策略的优势，
  - 并非来源于单个因子预测能力的统计显著增强，
  - 而更可能来自组合层面权重调整机制，
  - 对收益路径与风险暴露的工程性改良。

## 核心结论三：Regime 方法的边际贡献具有样本依赖性

- 在本研究样本区间内：
  - 引入 Regime 信息并未带来稳定的边际收益提升；
  - 含 Regime 的动态权重策略在部分指标上反而略逊。
- 需要强调的是：
  - 该结论并不否定 Regime 方法的理论合理性；
  - 而是反映其在样本期较短、状态转移有限条件下，
  - 难以稳定发挥增量信息的现实约束。



# 研究局限性

- 样本期长度有限
  - 样本外测试区间较短；
  - 年化指标对个别月份较为敏感。
- Regime 识别的简化假设
  - 基于有限的指数特征进行聚类；
  - 未显式刻画宏观或政策变量。
- 交易成本与市场冲击的近似处理
  - 回测主要通过换手率进行间接评估；
  - 未显式建模冲击成本与流动性约束。

# 未来研究方向

- 样本扩展与跨市场检验
  - 延长时间跨度；
  - 在其他指数或市场中检验稳健性。
- 更精细的市场状态刻画
  - 引入宏观、流动性或情绪变量；
  - 探索连续状态或状态转移模型。
- 权重映射与风险约束的改进
  - 在 softmax 映射中引入风险或换手惩罚；
  - 探索收益-风险联合优化的权重生成机制。

# 总结

- 本研究实证表明：
  - 即便在因子统计显著性并不突出的环境中，
  - 数据驱动的动态权重调整，
  - 仍可在组合层面显著改善收益-风险结构。
- 该发现为：
  - 因子轮动策略的工程实现，
  - 以及机器学习在多因子投资中的应用，
  - 提供了一种可复现、可扩展的研究范式。